



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۱

نام و نام خانوادگی
مجید صادقی نژاد

شماره دانشجویی
۸۱۰۱۰۱۴۵۹

۱۸ آبان ۱۴۰۴

۲	Bayes Rule vs. Random Decisions – سوال ۱	۱
۲	Overall Risk	۱.۱
۳	R_{Bayes} vs. R_{rand}	۲.۱
۳	Equal Performance	۳.۱
۴	Bayes Boundaries for Gaussian Classes – سوال ۲	۲
۴	Find Threshold	۱.۲
۵	2D Gaussian distributions	۲.۲
۸	Naive Bayes Parameter Estimation (MLE) – سوال ۳	۳
۸	Joint Log-Likelihood	۱.۳
۹	MLEs correspond to the empirical frequencies	۲.۳
۱۰	Modeling Goals with MLE – سوال ۴	۴
۱۰	MLE of λ	۱.۴
۱۰	Probability of 6 goals	۲.۴
۱۱	Updated numerical estimate of λ	۳.۴
۱۱	MLE Derivation of the Least Squares Loss – سوال ۵	۵
۱۱	The likelihood $p(y^{(i)} x^{(i)}; \theta, \sigma^2)$	۱.۵
۱۱	MLE and MSE	۲.۵
۱۲	Effect of Priors on the Decision Boundary – سوال ۶	۶
۱۳	Naive Bayes Warm-Up – سوال ۷	۷
۱۴	P(a person who tests positive is user)	۱.۷

١٤ Appropriate Naive Bayes model ٢.٧

١٥ **Classifying Spam with Naive Bayes – سوال ٨ ٨**

١٥ Dataset ١.٨

١٥ P(spam) and P(ham) ٢.٨

١٥ Conditional probabilities ٣.٨

١٦ Classify the test data ٤.٨

١٦ Vary the m parameter ٥.٨

١٧ If you were a spammer ٦.٨

١٧ **Cloud vs. Clear Sky – سوال ٩ ٩**

١٧ Define a criterion ١.٩

١٨ Confusion matrix ٢.٩

١٨ New classifiers ٣.٩

١٨ Misclassified images ٤.٩

١٩ New matrixes ٥.٩

فهرست تصاویر

۱	قطعه کد نمونه برداری و رسم مرز تصمیم بیزی	۷
۲	نتیجه ی نمونه برداری و رسم مرز تصمیم بیزی	۷
۳	پنج کلمه ی برتر محتمل برای کلاس های ham و spam	۱۵
۴	نمودار صحت مدل بر اساس مقدار m	۱۶
۵	تصاویری که توسط مدل اول، اشتباه کلاس بندی شده اند	۱۹
۶	تصاویری که توسط مدل دوم، اشتباه کلاس بندی شده اند	۱۹
۷	تصاویری که توسط مدل سوم، اشتباه کلاس بندی شده اند	۱۹

فهرست جداول

۱۶		میزان صحت مدل بیزی بر اساس m	۱
۱۸		Confusion matrix مدل اول	۲
۲۰		Confusion matrix مدل دوم	۳
۲۰		Confusion matrix مدل سوم	۴

در این تمرین به مباحث مربوط به کلاس بندی بیزی، شامل: تصمیم گیری بر اساس ریسک، مرز تصمیم، بهینه سازی پارامترهای توزیع های احتمالاتی با استفاده از MLE و وابستگی شدید تمام این مباحث به آمار و احتمال پرداخت شده.

در بخش اول تمرین با مباحث تئوری این مفاهیم آشنا می شویم و در بخش دوم تمرین به سراغ پیدا سازی کامپیوتری و استفاده ی عملی از کلاس بند بیزی می رویم و با تعدادی مسئله ی دنیای واقعی آشنا می شویم.

سوال ۱ - Bayes Rule vs. Random Decisions

۱.۱ Overall Risk

پیش از این دیدیم برای حالت Zero One Loss داریم:

$$Risk(\alpha_i|x) = 1 - p(w_i|x) \quad (۱)$$

بر اساس رابطه ی ۱، Conditional Risk برابر است با:

$$\begin{aligned} R_{rand}(\alpha(x)|x) &= \sum_{i=1}^k R(\alpha_i|x)p(\alpha_i) \\ &= \sum_{i=1}^k (1 - p(w_i|x))p(w_i|x) \\ &= \sum_{i=1}^k p(w_i|x) - p^2(w_i|x) \\ &= \sum_{i=1}^k p(w_i|x) - \sum_{i=1}^k p^2(w_i|x) \\ &= 1 - \sum_{i=1}^k p^2(w_i|x) \end{aligned} \quad (۲)$$

و بر طبق رابطه ی ۲، Overall Risk برابر است با:

$$R_{rand} = \int R_{rand}(\alpha(x)|x)p(x)dx$$

$$= \int (1 - \sum_{i=1}^k p^2(w_i|x))p(x)dx \quad (۳)$$

R_{Bayes} vs. R_{rand} ۲.۱

از آنجا که برای بهتر بودن یک Decision Rule لازم است که ریسک کمتری نسبت به مورد مقایسه دیگر داشته باشد، باید داشته باشیم:

$$R_{Bayes}(\alpha(x)|x) \leq R_{rand}(\alpha(x)|x) \quad (۴)$$

$$\Rightarrow 1 - \max_j p(w_j|x) \leq 1 - \sum_{i=1}^k p^2(w_i|x)$$

$$\Rightarrow \sum_{i=1}^k p^2(w_i|x) \leq \max_j p(w_j|x).1$$

$$\Rightarrow \sum_{i=1}^k p(w_i|x)p(w_i|x) \leq \max_j p(w_j|x). \sum_{i=1}^k p(w_i|x)$$

$$\Rightarrow \sum_{i=1}^k p(w_i|x)p(w_i|x) \leq \sum_{i=1}^k (p(w_i|x) \max_j p(w_j|x))$$

با توجه به این که خط آخر یک رابطه ی واضح و بدیهی ست پس اثبات می شود که روش بیزی روش بهتری نسبت به روش رندوم است.

Equal Performance ۳.۱

برای داشتن نتیجه ی یکسان توسط هر دو روش باید داشته باشیم:

$$R_{Bayes}(\alpha(x)|x) = R_{rand}(\alpha(x)|x)$$

$$\Rightarrow 1 - \max_j p(w_j|x) = 1 - \sum_{i=1}^k p^2(w_i|x)$$

$$\begin{aligned}
&\Rightarrow \sum_{i=1}^k p^2(w_i|x) = \max_j p(w_j|x).1 \\
&\Rightarrow \sum_{i=1}^k p(w_i|x)p(w_i|x) = \max_j p(w_j|x) \cdot \sum_{i=1}^k p(w_i|x) \\
&\Rightarrow \sum_{i=1}^k p(w_i|x)p(w_i|x) = \sum_{i=1}^k (p(w_i|x) \max_j p(w_j|x)) \\
&\Rightarrow \forall i, j [p(w_i|x) = p(w_j|x)] \quad (5)
\end{aligned}$$

بنابراین برای اینکه چنین چیزی محقق شود، باید تمام احتمال های پسین با یکدیگر برابر باشند و مقدار یکسان داشته باشند.

سوال ۲ - Bayes Boundaries for Gaussian Classes

Find Threshold ۱.۲

$$\begin{aligned}
&Risk(\alpha_1|x) \leq Risk(\alpha_2|x) \\
&\Rightarrow \lambda_{11}P(w_1|x) + \lambda_{12}P(w_2|x) \leq \lambda_{21}P(w_1|x) + \lambda_{22}P(w_2|x) \\
&\Rightarrow \lambda_{12}P(w_2|x) \leq \lambda_{21}P(w_1|x) \\
&\Rightarrow \lambda_{12}P(x|w_2)P(w_2) \leq \lambda_{21}P(x|w_1)P(w_1) \\
&\Rightarrow \frac{\lambda_{12}}{\sigma\sqrt{2\pi}}e^{-(x-1)^2/2\sigma^2}P(w_2) \leq \frac{\lambda_{21}}{\sigma\sqrt{2\pi}}e^{-x^2/2\sigma^2}P(w_1) \\
&\Rightarrow \lambda_{12}e^{-(x-1)^2/2\sigma^2}P(w_2) \leq \lambda_{21}e^{-x^2/2\sigma^2}P(w_1) \\
&\Rightarrow \frac{\lambda_{12}P(w_2)}{\lambda_{21}P(w_1)} \leq \exp\left(\frac{(x-1)^2 - x^2}{2\sigma^2}\right)
\end{aligned}$$

$$\Rightarrow \ln\left(\frac{\lambda_{12}P(w_2)}{\lambda_{21}P(w_1)}\right) \leq \frac{-2x+1}{2\sigma^2}$$

$$\Rightarrow \frac{1}{2} - \sigma^2 \ln\left(\frac{\lambda_{12}P(w_2)}{\lambda_{21}P(w_1)}\right) \geq x$$

$$\Rightarrow \boxed{\tau = \frac{1}{2} - \sigma^2 \ln\left(\frac{\lambda_{12}P(w_2)}{\lambda_{21}P(w_1)}\right)}$$

2D Gaussian distributions ۲.۲

آ.

$$g_i(x) = \ln(P(x|w_i)P(w_i)) = \ln P(x|w_i) + \ln P(w_i)$$

$$\ln p(x | \omega_i) = -\frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} (x - \mu_i)^T \Sigma^{-1} (x - \mu_i)$$

از آنجایی که می دانیم:

$$-\frac{d_1}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_1| = -\frac{d_2}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_2|$$

$$\Rightarrow g_i(x) = -\frac{1}{2} (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) + \ln P(\omega_i).$$

و می دانیم:

$$\Sigma = 3I, \Sigma^{-1} = \frac{1}{3}I$$

$$\Rightarrow g_i(x) = -\frac{1}{6} |x - \mu_i|^2 + \ln P(\omega_i)$$

$$\Rightarrow \boxed{g_1(x) = -\frac{1}{6} |x - (4, 11)|^2 + \ln 0.6}$$

$$\Rightarrow \boxed{g_2(x) = -\frac{1}{6} |x - (10, 3)|^2 + \ln 0.4}$$

ب.

$$g_1(x) = g_2(x)$$

$$-\frac{1}{6} |x - (4, 11)|^2 + \ln 0.6 = -\frac{1}{6} |x - (10, 3)|^2 + \ln 0.4$$

$$|x - (10, 3)|^2 - |x - (4, 11)|^2 = 6 \ln \frac{0.6}{0.4}$$

$$-14 - 6x_1 + 8x_2 = 3 \ln 1.5$$

$$x_2 = \frac{3}{4}x_1 + \frac{7}{4} + \frac{3}{8} \ln 1.5$$

$$\Rightarrow \boxed{x_2 \approx 0.75x_1 + 1.902}$$

ج. • تغییر در احتمال‌های پیشین:

در معادله‌ی مرز تصمیم، جمله‌ای از نوع $(6 \ln \frac{P_1}{P_2})$ وجود دارد. وقتی احتمال‌های پیشین (P_1) و (P_2) را تغییر دهیم، این جمله‌ی ثابت تغییر می‌کند. در نتیجه مرز تصمیم جابه‌جا می‌شود، یعنی خط به سمت کلاسی حرکت می‌کند که احتمال پیشین بیشتری دارد. اما شیب خط تغییر نمی‌کند، مادامی که کوواریانس‌ها Σ برای هر دو کلاس برابر باشند.

• تغییر در ماتریس کوواریانس‌ها:

اگر هر دو کلاس کوواریانس یکسانی داشته باشند (حتی اگر ماتریس واحد نباشد)، مرز تصمیم همچنان خطی باقی می‌ماند. در این حالت، معادله‌ی مرز به صورت زیر است:

$$(\mu_1 - \mu_2)^T \Sigma^{-1} x = \text{const}$$

یعنی مرز تصمیم، یک خط مستقیم وزن‌دهی شده با Σ^{-1} است. اما اگر کوواریانس دو کلاس متفاوت باشد ($\Sigma_1 \neq \Sigma_2$)، در این صورت جمله‌های درجه دوم در معادله حذف نمی‌شوند و مرز تصمیم به شکل درجه دوم در می‌آید.

د. پس از انجام فرایند توصیف شده به کمک یک قطعه کد پایتون که در تصویر ۱ نشان داده شده است تصویر ۲ به دست آمد که نشان دهنده‌ی نمونه‌ها به همراه خط مرز تصمیم است.

```

import numpy as np
import matplotlib.pyplot as plt

np.random.seed(0)
mu1 = np.array([4.0, 11.0])
mu2 = np.array([10.0, 3.0])
Sigma = 3.0 * np.eye(2)
P1 = 0.6
P2 = 0.4
n = 100

samples1 = np.random.multivariate_normal(mu1, Sigma, size=n)
samples2 = np.random.multivariate_normal(mu2, Sigma, size=n)

xmin = min(samples1[:,0].min(), samples2[:,0].min()) - 3
xmax = max(samples1[:,0].max(), samples2[:,0].max()) + 3
ymin = min(samples1[:,1].min(), samples2[:,1].min()) - 3
ymax = max(samples1[:,1].max(), samples2[:,1].max()) + 3

xx, yy = np.meshgrid(np.linspace(xmin, xmax, 400), np.linspace(ymin, ymax, 400))
grid = np.c_[xx.ravel(), yy.ravel()]

Sigma_inv = np.linalg.inv(Sigma)

def g(x, mu, P):
    diff = x - mu
    return -0.5 * np.sum(diff @ Sigma_inv * diff, axis=1) + np.log(P)

g1 = g(grid, mu1, P1)
g2 = g(grid, mu2, P2)

decision = (g1 > g2).astype(int).reshape(xx.shape)


fig, ax = plt.subplots(figsize=(8,6))
ax.contourf(xx, yy, decision, levels=[-0.5, 0.5, 1.5], alpha=0.2)
ax.scatter(samples1[:,0], samples1[:,1], label='salmon (u=1)', marker='x')
ax.scatter(samples2[:,0], samples2[:,1], label='sea bass (u=2)', marker='x')

B = 0.5 * (5*np.log(P1/P2) + (mu1 @ mu1) - (mu2 @ mu2))
x_vals = np.linspace(xmin, xmax, 200)
y_vals = (B + 6*x_vals) / 8
ax.plot(x_vals, y_vals, '--', linewidth=2, label='Bayes decision boundary')

ax.set_xlim(xmin, xmax)
ax.set_ylim(ymin, ymax)
ax.set_xlabel('x1')
ax.set_ylabel('x2')
ax.set_title('Samples and Bayes decision boundary ( $\Sigma = 3I$ ,  $P1=0.6$ ,  $P2=0.4$ )')
ax.legend()
plt.tight_layout()
plt.show()

```

شکل ۱: قطعه کد نمونه برداری و رسم مرز تصمیم بیزی



شکل ۲: نتیجه ی نمونه برداری و رسم مرز تصمیم بیزی

سوال ۳ - Naive Bayes Parameter Estimation (MLE)

۱.۳ Joint Log-Likelihood

پارامتری هایی که داریم به شکل زیر است:

$$\phi = \{\phi_y, \phi_{j|y=0}, \phi_{j|y=1}\}_{j=1}^n$$

بنابراین برای یک نمونه $(x^{(i)}, y^{(i)})$ داریم:

$$p(x^{(i)}, y^{(i)}; \phi) = p(y^{(i)}; \phi_y) \prod_{j=1}^n p(x_j^{(i)} | y^{(i)}; \phi_{j|y})$$

از آنجایی که توزیع برنولی است، داریم:

$$p(x_j^{(i)} | y^{(i)} = b) = (\phi_{j|y=b})^{x_j^{(i)}} (1 - \phi_{j|y=b})^{1-x_j^{(i)}}$$

و برای یافتن likelihood روی کل داده ها داریم:

$$L(\phi) = \prod_{i=1}^m p(y^{(i)}; \phi_y) \prod_{j=1}^n (\phi_{j|y^{(i)}})^{x_j^{(i)}} (1 - \phi_{j|y^{(i)}})^{1-x_j^{(i)}}$$

و برای پیدا کردن log-likelihood $(\ell(\phi) = \ln L(\phi))$:

$$\begin{aligned} \ell(\phi) &= \sum_{i=1}^m \left[y^{(i)} \ln \phi_y + (1 - y^{(i)}) \ln(1 - \phi_y) \right] \\ &+ \sum_{i=1}^m \sum_{j=1}^n \left[x_j^{(i)} \ln \phi_{j|y^{(i)}} + (1 - x_j^{(i)}) \ln(1 - \phi_{j|y^{(i)}}) \right] \end{aligned}$$

MLEs correspond to the empirical frequencies ۲.۳

با جداسازی بخش مربوط به ϕ_y از $\ell(\phi)$:

$$\ell_y(\phi_y) = \sum_{i=1}^m [y^{(i)} \ln \phi_y + (1 - y^{(i)}) \ln(1 - \phi_y)]$$

اگر در نظر بگیریم که $m_1 = \sum_{i=1}^m y^{(i)}$ تعداد داده هایی است که $y = 1$ و $m_0 = m - m_1$ تعداد کل داده ها و m_0 تعداد داده هایی است که $y = 0$:

$$\ell_y(\phi_y) = m_1 \ln \phi_y + m_0 \ln(1 - \phi_y)$$

و برای پیدا کردن MLE:

$$\frac{d\ell_y}{d\phi_y} = \frac{m_1}{\phi_y} - \frac{m_0}{1 - \phi_y} = 0$$

$$\Rightarrow \frac{m_1}{\phi_y} = \frac{m_0}{1 - \phi_y} \Rightarrow m_1(1 - \phi_y) = m_0\phi_y$$

$$\Rightarrow m_1 = m\phi_y \Rightarrow \boxed{\phi_y = \frac{m_1}{m}}$$

که با حالت تجربی فرکانسی منطبق است. حال فرض می کنیم:

$$N_{j,b} = \sum_{i:y^{(i)}=b} x_j^{(i)} \quad \text{تعداد دفعاتی که } x_j = 1 \text{ است در کلاس } b$$

بخشی از $\ell(\phi)$ که مربوط به $\phi_{j|y=b}$ است:

$$\ell_{j,b}(\phi_{j|y=b}) = N_{j,b} \ln \phi_{j|y=b} + (m_b - N_{j,b}) \ln(1 - \phi_{j|y=b}).$$

$$\Rightarrow \frac{d\ell_{j,b}}{d\phi_{j|y=b}} = \frac{N_{j,b}}{\phi_{j|y=b}} - \frac{m_b - N_{j,b}}{1 - \phi_{j|y=b}} = 0$$

$$\Rightarrow \frac{N_{j,b}}{\phi_{j|y=b}} = \frac{m_b - N_{j,b}}{1 - \phi_{j|y=b}} \Rightarrow N_{j,b} = m_b \phi_{j|y=b} \Rightarrow \boxed{\phi_{j|y=b} = \frac{N_{j,b}}{m_b}}$$

که مجدداً با حالت تجربی فرکانسی منطبق است.

سوال ۴ - Modeling Goals with MLE

۱.۴ MLE of λ

برای محاسبه ی likelihood تعداد n داده داریم:

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = e^{-n\lambda} \lambda^{\sum_{i=1}^n x_i} \prod_{i=1}^n \frac{1}{x_i!}.$$

و محاسبه ی log-likelihood به شکل زیر است (عبارت $-\sum_i \ln x_i!$ که ارتباطی به λ به شکل مقدار ثابت در نظر گرفته شده است):

$$\ell(\lambda) = \ln L(\lambda) = -n\lambda + \left(\sum_{i=1}^n x_i \right) \ln \lambda + \text{const}$$

$$\Rightarrow \frac{d\ell}{d\lambda} = -n + \frac{1}{\lambda} \sum_{i=1}^n x_i = 0 \quad \Rightarrow \quad \lambda = \frac{1}{n} \sum_{i=1}^n x_i$$

۲.۴ Probability of 6 goals

داده ای که تاکنون داریم به این شکل است:

$$x = [2, 4, 6, 0, 1]$$

بنابراین:

$$\lambda = \frac{13}{5} = 2.6$$

و احتمال زدن ۶ گل در بازی بعدی برابر است با

$$P(X = 6) = \frac{e^{-2.6}(2.6^6)}{6!} \approx 0.031867 \approx 3.19\%$$

۳.۴ Updated numerical estimate of λ

بر اساس داده های جدید مجددا پارامتر را محاسبه می کنیم:

$$\lambda_6 = \frac{21}{6} = 3.5$$

احتمال زدن شش گل در بازی بعدی (بازی هفتم):

$$P(X = 6) = \frac{e^{-3.5}(3.5^6)}{6!} \approx 0.077098 \approx 7.71\%$$

سوال ۵ - MLE Derivation of the Least Squares Loss

۱.۵ The likelihood $p(y^{(i)} | x^{(i)}; \theta, \sigma^2)$

از آنجا که توزیع $\epsilon^{(i)}$ گاوسی است و $y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$ ، توزیع شرطی $y^{(i)}$ به شرط $x^{(i)}$ گاوسی است با میانگین $(\theta^T x^{(i)})$ و واریانس σ^2 :

$$p(y^{(i)} | x^{(i)}; \theta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-1}{2\sigma^2}(y^{(i)} - \theta^T x^{(i)})^2\right)$$

۲.۵ MLE and MSE

joint likelihood برای n نقطه برابر است با:

$$L(\theta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-1}{2\sigma^2}(y^{(i)} - \theta^T x^{(i)})^2\right)$$

$$\Rightarrow \ell(\theta, \sigma^2) = \ln L(\theta, \sigma^2)$$

$$= \sum_{i=1}^n \left[\frac{-1}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (y^{(i)} - \theta^T x^{(i)})^2 \right]$$

$$= \frac{-n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2$$

با جدا سازی بخشی از رابطه که مربوط به θ است به رابطه ای می رسیم که قصد ماکسیم کردن آن را داریم (جهت پیدا کردن بهترین θ):

$$\frac{-1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2$$

برای ماکسیم کردن عبارت بالا باید عبارت پایین را مینیم کنیم:

$$\sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2$$

که این عبارت دقیقا عبارتی است که برای مینیم کردن MSE باید آن را مینیم کنیم بنابراین مینیم کردن MSE و ماکسیم کردن MLE هر دو به یک عبارت می رسند و معادل یکدیگر هستند.

سوال ۶ - Effect of Priors on the Decision Boundary

در نظر می گیریم:

$$P(\omega_1) = P_1 \quad P(\omega_2) = P_2$$

و طبق تصمیم بیزی برای یافتن مرز تصمیم:

$$p(x | \omega_1)P_1 = p(x | \omega_2)P_2$$

$$\Rightarrow \frac{p(x | \omega_1)}{p(x | \omega_2)} \cdot \frac{P_1}{P_2} = 1$$

با گرفتن لگاریتم از رابطه ی بالا برای سادگی داریم:

$$\ln \frac{p(x | \omega_1)}{p(x | \omega_2)} + \ln \frac{P_1}{P_2} = 0$$

از آنجایی که توزیع ها گاوسی با واریانس یکسان است داریم:

$$\ln \frac{p(x | \omega_1)}{p(x | \omega_2)} = -\frac{(x - \mu_1)^2}{2\sigma^2} + \frac{(x - \mu_2)^2}{2\sigma^2} = \frac{(x - \mu_2)^2 - (x - \mu_1)^2}{2\sigma^2}$$

و مرز تصمیم برابر است با:

$$\frac{(x^* - \mu_2)^2 - (x^* - \mu_1)^2}{2\sigma^2} + \ln \frac{P_1}{P_2} = 0$$

$$\Rightarrow x^* = \frac{\mu_1 + \mu_2}{2} - \frac{\sigma^2}{\mu_1 - \mu_2} \ln \frac{P_1}{P_2}$$

اگر P_1 نسبت به P_2 افزایش یابد، آنگاه $\ln \frac{P_1}{P_2}$ بزرگتر می شود. با توجه به فرمول کلی مرز تصمیم، علامت جابه جایی x^* به علامت $(\mu_1 - \mu_2)$ بستگی دارد. اگر $(\mu_1 > \mu_2)$ باشد، در این حالت $(\mu_1 - \mu_2 > 0)$ ، بنابراین جمله ی $\frac{\sigma^2}{\mu_1 - \mu_2} \ln \left(\frac{P_1}{P_2} \right)$ مثبت است وقتی $(P_1 > P_2)$. از آنجایی که این جمله از میانگین ها کم می شود، نتیجه می گیریم که: x^* کاهش می یابد. افزایش P_1 یعنی ما بیشتر انتظار داریم داده ها از کلاس ۱ باشند. بنابراین، حتی اگر مقدار (x) کمی به کلاس ۲ نزدیک تر باشد، باز هم تمایل داریم آن را کلاس ۱ در نظر بگیریم. در نتیجه، مرز تصمیم به سمت کلاس ۲ (سمت چپ، با میانگین کمتر) جابه جا می شود و ناحیه ی تصمیم برای کلاس ۱ بزرگتر می شود. و اگر $\mu_1 < \mu_2$ باشد در این صورت $(\mu_1 - \mu_2 < 0)$ ، و با همان استدلال، افزایش P_1 باعث می شود (x^*) افزایش پیدا کند (به راست حرکت کند) یعنی مرز تصمیم به سمت کلاسی با احتمال کمتر حرکت می کند تا ناحیه ی کلاس با احتمال بزرگتر بیشتر شود.

سوال ۷ - Naive Bayes Warm-Up

۱.۷ P(a person who tests positive is user)

$$P(T = 1|D = 1) = 0.99$$

$$P(T = 0|D = 0) = 0.99 \Rightarrow P(T = 1|D = 0) = 0.01$$

$$P(D = 1) = 0.001 \Rightarrow P(D = 0) = 0.999$$

$$\begin{aligned} P(D = 1|T = 1) &= \frac{P(T = 1|D = 1)P(D = 1)}{P(T = 1|D = 1)P(D = 1) + P(T = 1|D = 0)P(D = 0)} \\ &= \frac{(0.99)(0.001)}{0.00099 + 0.00999} \approx 0.0901639 \approx 9\% \end{aligned}$$

۲.۷ Appropriate Naive Bayes model

آ. $(y = 1)$ ، ۵ بار ظاهر شده است و $(y = 0)$ نیز ۵ بار مشاهده است و تعداد کل مشاهدات برابر ۱۰ عدد است بنابراین:

$$P(y = 1) = 0.5, \quad P(y = 0) = 0.5$$

ب. ردیف های $(y = 1)$: $(0, 1), (1, 1), (1, 1), (1, 1), (1, 1)$

$$P(x_1 = 1|y = 1) = \frac{4}{5} = 0.8, \quad P(x_2 = 1|y = 1) = \frac{5}{5} = 1.0$$

ردیف های $y = 0$: $(0, 0), (0, 0), (1, 0), (1, 0), (1, 0)$

$$P(x_1 = 1|y = 0) = \frac{3}{5} = 0.6, \quad P(x_2 = 1|y = 0) = \frac{0}{5} = 0.0$$

ج.

$$P(y = 1 | x = (1, 1)) = (0.8)(1.0)(0.5) = 0.4$$

$$P(y = 0 | x = (1, 1)) = (0.6)(0.0)(0.5) = 0.0$$

بنابراین نتیجه ی نهایی $y = 1$ است.

```

Top 5 words given spam:
enron: 3.819439e-02
at: 2.361853e-02
corp: 2.173791e-02
the: 2.142518e-02
to: 1.968704e-02

Top 5 words given ham:
aaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaa: 4.432171e-02
enron: 4.244372e-02
the: 3.316908e-02
to: 2.532968e-02
at: 1.773666e-02

```

شکل ۳: پنج کلمه ی برتر محتمل برای کلاس های spam و ham

سوال ۸ - Classifying Spam with Naive Bayes

۱.۸ Dataset

مجموعه داده ی مربوط را load می کنیم داده ی که داده ی آموزش شامل ۹۰۰۰ ردیف و داده ی تست شامل ۱۰۰۰ ردیف است و هر ردیف شامل کلمات یک ایمیل و تعداد آن هاست.

۲.۸ $P(\text{spam})$ and $P(\text{ham})$


بر اساس داده ی آموزش احتمال های خواسته شده را محاسبه می کنیم:

Number of spams: 5163, Number of hams: 3837

$$P(\text{spam}) = 0.573667, \quad P(\text{ham}) = 0.426333$$

۳.۸ Conditional probabilities

حال بر اساس کلمات داده های آموزش احتمال شرطی هر کلمه با توجه به کلاس spam یا ham را محاسبه می کنیم. همچنین از آنجا که ممکن است تعدادی از این احتمالات برابر ۰ بشوند و کل فرایند تصمیم گیری بیزی که بر اساس ضرب احتمال هاست را دچار مشکل بکنند باید از m-estimate استفاده کنیم (که معادل Laplace Smoothing [۱] است)، در نهایت بر اساس احتمال های محاسبه شده، ۵ کلمه ی برتر محتمل spam و ham در شکل ۳ آمده است.



شکل ۴: نمودار صحت مدل بر اساس مقدار m

m	Accuracy
1000	0.9020
10000	0.9040
100000	0.9040
1000000	0.8710
10000000	0.7650

جدول ۱: میزان صحت مدل بیزی بر اساس m

۴.۸ Classify the test data

در نهایت با کلاس بندی داده ی آزمون بر اساس مدل بیزی با استفاده از احتمال هایی که به دست آوردیم به صحت (Accuracy) 90.2% می رسیم (توجه شود که این دقت با در نظر گرفتن $m = |V|$ به دست آمده است).

۵.۸ Vary the m parameter

با امتحان کردن مقادیر متفاوت به ازای m به این نتیجه دست پیدا می کنیم که در صورتی که m بسیار بزرگ باشد توجه مدل به احتمال های شرطی که از داده به دست آمده اند کاهش می یابد و صحت مدل کاهش می یابد و در واقع پدیده ی underfit را داریم و در صورتی که m بسیار کوچک باشد مدل بسیار زیاد به احتمال های پیشین که مستقیماً از داده ها به دست آورده وابسته می شود و در واقع overfit می شود، همچنین میزان صحت مدل به ازای m های متفاوت در شکل ۴ و جدول ۱ قابل مشاهده است.

۶.۸ If you were a spammer

اگر قرار بود ایمیل طراحی کنیم که مدل نتواند آن را به درستی کلاس بندی کند باید:

- تعداد زیادی از کلمه هایی که به عنوان کلمه های محتمل دسته ی ham تشخیص داده شدند در متن ایمیل بگنجانیم.
- از علائم نوشتاری و سایر کاراکتر هایی که کلمه نیستند استفاده کنیم تا مدل نتواند به عنوان کلمه از آن ها استفاده کند و smoothing بر احتمال های شرطی غالب شود.
- متن را در عکس یا فرمت HTML بنویسم تا اساس عملکرد مدل که بر اساس شمارش و کلمات است، مختل شود

سوال ۹ - Cloud vs. Clear Sky

۱.۹ Define a criterion

مدلی که انتخاب شد به این صورت فعالیت می کند که دو ویژگی بر اساس رنگ RGB تصویر تعریف می کند، ویژگی اول میزان خاکستری بودن تصویر در ۴۰ درصد بالایی تصویر را می سنجد و ویژگی دوم میزان گرم بودن (نارنجی، قرمز و زرد بودن)، کل تصویر را می سنجد سپس بر اساس این دو ویژگی رابطه ی زیر تعریف می شود:

انتخاب این ویژگی ها بر اساس مشاهده ی مجموعه ی داده فراهم شده است اکثر تصاویر دارای آسمان صاف در زمان غروب خورشید گرفته شده اند بنابراین می توان استدلال کرد که در صورتی که تصویر دارای ویژگی های زمان غروب خورشید بود پس آسمان صاف است و اکثر تصاویر ابری فضای رنگی غالب خاکستری دارند بنابراین می توان استدلال کرد در صورتی که تصویر فضای رنگی خاکستری داشت پس ابری است.

$$\text{cloud_score} = \text{gray_top} - 0.5(\text{warm_all})$$

که هر میزان امتیاز ابری بودن بیشتر باشد به احتمال بالاتری کلاس تصویر برابر با ابری است. سپس بر اساس تصاویری که در اختیار داریم به دنبال threshold ای برای این رابطه می گردیم

TP	32
FP	4
FN	8
TN	36

جدول ۲: Confusion matrix مدل اول

که در صورتی که امتیاز ابری بودن تصویری بیشتر از آن آستانه بود آن را به عنوان آسمان ابری تشخیص می دهیم. روش جستجوی آستانه نیز به این صورت است که به دنبال آستانه ای که هستیم که در صورت که آن را در مدل استفاده کنیم بیشترین تعداد تصویر به درستی کلاس بندی شوند.

۲.۹ Confusion matrix

در این مدل کلاس مثبت (positive) را معادل حالت ابری در نظر می گیریم شکل Confusion matrix در جدول ۲ آمده است همچنین وضعیت عملکردی مدل به شکل زیر است:


$$Precision = 0.89, \quad Recall = 0.80, \quad Accuracy = 0.85$$

۳.۹ New classifiers

دو مدل دیگر بر اساس ویژگی های رنگی RGB تصاویر طراحی شد که همانند مدل اول دو ویژگی استخراج می کنند و بر اساس آن دو ویژگی، رابطه ی امتیاز ابری بودن را ارائه می دهند در مدل دوم میزان آبی بودن تصویر و میزان قرمز بودن آن به عنوان دو ویژگی استخراج می شوند و امتیاز ابری بودن برابر با تفاضل این دو ویژگی است و در مدل سوم میزان خاکستری و گرم بودن کل تصویر به عنوان دو ویژگی استخراج می شود و امتیاز ابری بودن نسبت این دو ویژگی به یک دیگر است.

۴.۹ Misclassified images

با توجه به این که ویژگی آسمان صاف را به ویژگی غروب خورشید مربوط کردیم بیشترین خطا در زمانی اتفاق می افتد که تصویر فضای رنگی غروب خورشید را دارد اما آسمان ابری است این



شکل ۵: تصاویری که توسط مدل اول، اشتباه کلاس بندی شده اند



شکل ۶: تصاویری که توسط مدل دوم، اشتباه کلاس بندی شده اند

موضوع در رابطه با هر سه مدل برقرار است. در شکل های ۵، ۶، ۷ تعدادی از تصاویری که توسط هر مدل به اشتباه دسته بندی شده اند آورده شده است.

۵.۹ New matrixes

نتیجه ی عملکردی مدل دوم:

$$Precision = 0.85, \quad Recall = 0.85, \quad Accuracy = 0.85$$

نتیجه ی عملکردی مدل سوم:

$$Precision = 1.00, \quad Recall = 0.75, \quad Accuracy = 0.88$$



شکل ۷: تصاویری که توسط مدل سوم، اشتباه کلاس بندی شده اند

TP	34
FP	6
FN	6
TN	34

جدول ۳: Confusion matrix مدل دوم

TP	30
FP	0
FN	10
TN	40

جدول ۴: Confusion matrix مدل سوم

همانطور که دیدی می شود، مدل سوم به لحاظ صحت عملکرد بهتری نسبت به دو مدل دیگر دارد. همچنین Confusion matrix مدل های دوم و سوم در جدول های ۳ ، ۴ نشان داده شده است.

Bayes Naive in Smoothing “Laplace Science, Data Towards [١]
https://towardsdatascience.com/ Available: Algorithm.”
.laplace-smoothing-in-naive-bayes-algorithm-9c237a8bdece/
.٢٠٢٥ Nov. ٩ Accessed: