



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



BlackBox – سامانه‌ی ثبت، جست‌وجو و

بازپخش رخدادها

درس کارگاه کامپیوتر

دستور کار جلسه پایانی

تهیه‌کننده:

سینا ساعدی سعدآباد

استاد:

دکتر سیامک محمدی

پاییز ۱۴۰۴

P [REDACTED]
S [REDACTED]
M [REDACTED]

۱. هدف پروژه و خروجی مطلوب

این پروژه برای طراحی و پیاده‌سازی یک سامانه‌ی نرم‌افزاری است که جریان پیام‌های دریافتی از چند منبع را دریافت می‌کند، آن‌ها را اعتبارسنجی و استاندارد می‌کند، داده‌ی معتبر را به شکل پایدار ذخیره می‌کند، رخدادهای معنی‌دار را استخراج و ثبت می‌کند، و در نهایت امکان مشاهده‌ی وضعیت، جست‌وجوی رخدادهای و تولید گزارش نهایی را فراهم می‌سازد. خروجی مطلوب پروژه یک «سیستم قابل اجرا» است که روی لپ‌تاپ (ویندوز یا لینوکس) بدون وابستگی به برد اجرا می‌شود و پس از یک اجرای چند دقیقه‌ای، مجموعه‌ای از خروجی‌های قابل بررسی تولید می‌کند؛ این خروجی‌ها باید آن‌قدر شفاف و ساختارمند باشند که یک شخص ثالث بتواند با نگاه به آن‌ها بفهمد چه داده‌ای وارد سیستم شده، چه بخشی از داده نامعتبر بوده، چه رخدادهایی تشخیص داده شده و وضعیت سامانه در طول اجرا چگونه تغییر کرده است.

در تحویل نهایی انتظار می‌رود علاوه بر کد، یک بسته‌ی خروجی شامل داده‌ی خام ذخیره‌شده، داده‌ی تمیز و ساختار یافته، فهرست رخدادهای ثبت خطاها و یک گزارش خودکار از نتایج وجود داشته باشد. این گزارش خودکار باید از روی خروجی‌های ساختاریافته تولید شود، نه اینکه به صورت دستی نوشته شده باشد. همچنین سامانه باید یک روش روشن برای مشاهده‌ی وضعیت لحظه‌ای ارائه کند؛ مشاهده‌ی وضعیت می‌تواند از طریق یک صفحه‌ی ساده روی مرورگر یا یک API محلی روی localhost انجام شود، اما باید به داده‌ی واقعی سیستم متصل باشد و صرفاً یک چاپ ساده در ترمینال نباشد.

۲. شرط تنوع پروژه و کاهش شباهت بین تحویل‌ها

برای این پروژه یک بخش «فرض سناریو» اجباری است. هر دانشجو باید یک سناریوی کاربردی مشخص برای سامانه تعریف کند و پروژه را برای همان سناریو توسعه دهد. سناریو صرفاً یک داستان کوتاه نیست؛ باید روی شکل داده‌ی ورودی، نوع رخدادهای، قواعد تشخیص رخداد و گزارش خروجی اثر واقعی بگذارد. علاوه بر انتخاب سناریو، هر دانشجو موظف است یک «فرض محدودیت یا ریسک» نیز تعریف کند و اثر آن را در سیستم پیاده‌سازی کند. این فرض می‌تواند مثلاً از جنس قطع و وصل شدن ارتباط بین منبع و سامانه، محدود بودن فضای ذخیره، نیاز به ناشناس‌سازی شناسه‌ها و حذف اطلاعات حساس، یا رسیدن پیام‌ها به صورت نامرتب باشد. انتخاب فرض آزاد است، اما باید در گزارش توضیح داده شود و در رفتار سیستم قابل مشاهده باشد.

برای قابل ارزیابی بودن تنوع، لازم است سناریوی انتخابی و فرض محدودیت در فایل پیکربندی پروژه ثبت شود و تولید داده‌ی شبیه‌سازی‌شده نیز به یک مقدار seed وابسته باشد که از شماره‌های دانشجویی مشتق می‌شود یا به صورت صریح در پیکربندی نوشته می‌شود.

۳. چارچوب فنی پروژه و انتظارات سطح سیستم

پروژه باید چندبخشی طراحی شود و اجزا نقش‌های روشن داشته باشند. انتظار می‌رود حداقل یک جزء نقش «تولیدکننده‌ی داده» را بازی کند و چند منبع متفاوت را شبیه‌سازی کند، یک جزء نقش «هسته‌ی دریافت و پردازش» را داشته باشد و مسئول اعتبارسنجی، استانداردسازی و ذخیره‌ی پایدار باشد، و یک جزء نقش «ارائه‌ی وضعیت و جست‌وجو» را بر عهده بگیرد. ارتباط بین اجزا باید واقعی باشد و با سازوکار ارتباطی استاندارد انجام شود؛ مناسب‌ترین انتخاب برای این هدف ارتباط مبتنی بر socket روی localhost است، زیرا روی ویندوز و لینوکس به صورت یکسان عمل می‌کند. قالب پیام‌ها باید ساختاریافته باشد و به صورت JSON تولید و تبادل شود، و برای جلوگیری از ابهام در مرزبندی پیام‌ها لازم است قرارداد پیام‌ها به شکل «هر پیام یک خط» تعریف شود تا هم روی کانال ارتباطی و هم در فایل خام ذخیره‌شده قابل جداسازی و بازپخش باشد.

در بخش ذخیره‌سازی، داده‌ی معتبر و رخدادهای استخراج‌شده باید به صورت پایدار نگهداری شوند. برای این هدف، استفاده از SQLite پیشنهاد می‌شود زیرا روی همه‌ی سیستم‌عامل‌ها بدون نصب اضافی در دسترس است و به صورت استاندارد امکان جست‌وجو، شاخص‌گذاری و گزارش‌گیری را فراهم می‌کند. داده‌ی خام نیز باید جداگانه ذخیره شود تا بازپخش امکان‌پذیر باشد. توجه شود که ذخیره‌ی خام و ذخیره‌ی تمیز دو هدف متفاوت دارند و هر دو در ارزیابی نقش دارند؛ ذخیره‌ی خام برای بازتولید و اشکال‌زدایی است و ذخیره‌ی تمیز برای تحلیل و گزارش‌گیری.

۴. قابلیت‌هایی که سامانه باید ارائه کند

سامانه باید بتواند پیام‌ها را دریافت کند، قالب پیام را بررسی کند، فیلدهای لازم را اعتبارسنجی کند و در صورت نامعتبر بودن پیام، آن را همراه با دلیل و زمان دریافت در بخش خطاها ثبت کند. پیام معتبر باید به یک رکورد استاندارد تبدیل شود و در ذخیره‌ی پایدار نوشته شود. علاوه بر این، سامانه باید بتواند رخدادها را تشخیص دهد؛ رخدادها باید در سناریوی شما تعریف شوند و شامل دست کم یک رخداد مبتنی بر آستانه، یک رخداد مبتنی بر پنجره‌ی زمانی، و یک رخداد مبتنی بر «کیفیت داده یا قطع شدن جریان» باشند. رخدادها باید جداگانه ذخیره شوند و قابل جست‌وجو باشند، به این معنی که بتوان خروجی گرفت که مثلاً در بازه‌ی زمانی مشخص چه رخدادهایی رخ داده و برای کدام منبع بوده است.

بخش ارائه‌ی وضعیت باید حداقل این تصویر را بدهد که آخرین پیام معتبر هر منبع چه زمانی دریافت شده، آخرین مقدار معتبر چیست، چه تعداد پیام نامعتبر تاکنون ثبت شده و چه رخدادهایی اخیراً ایجاد شده است. لازم نیست رابط کاربری پیچیده باشد، اما باید قابل استفاده و قابل اتکا باشد و از داده‌ی واقعی سیستم تغذیه شود.

در کنار اجرای زنده، سامانه باید یک قابلیت بازپخش داشته باشد. بازپخش یعنی داده‌ی خام ذخیره‌شده‌ی یک اجرای قبلی دوباره به سامانه تزریق شود و سیستم دوباره همان جریان را پردازش کند و خروجی‌های قابل مقایسه تولید کند. بازپخش لازم نیست زمان‌بندی

دقیقی در حد میلی ثانیه داشته باشد، اما باید قابل کنترل باشد و امکان تنظیم سرعت بازپخش وجود داشته باشد تا بررسی رخدادهای و اشکال زدایی عملی شود.

در پایان هر اجرا، سامانه باید بتواند یک گزارش خودکار تولید کند که از روی ذخیره‌ی پایدار و رخدادهای ساخته می‌شود. گزارش باید شامل آمار کلی، کیفیت داده، مهم‌ترین رخدادهای و جمع‌بندی سناریوی اجرا باشد. گزارش می‌تواند متنی یا Markdown باشد، اما باید ساختار مشخص و قابل خواندن داشته باشد.

۵. راهنمای آموزشی کوتاه

در این پروژه، پیام‌محوری اهمیت دارد، بنابراین دانشجو باید با ساختار JSON و مفهوم JSON Lines آشنا باشد و بداند چرا رمزبندی پیام‌ها در کانال‌های جریانی مسئله است. همچنین لازم است مفهوم زمان دریافت، زمان تولید و تفاوت آن‌ها در تحلیل رخداد درک شود، زیرا رخدادهای پنجره‌ای بدون مدیریت صحیح زمان عملایی اعتبار می‌شوند. برای ذخیره‌ی پایدار، دانشجو باید بداند SQLite یک پایگاه داده‌ی محلی است که امکان ساخت جدول، درج رکورد، جست‌وجو و شاخص‌گذاری را می‌دهد و در پایتون از طریق ماژول sqlite3 قابل استفاده است. برای ارائه‌ی وضعیت، دانشجو باید بداند می‌توان با قابلیت‌های استاندارد پایتون یک سرویس ساده روی localhost راه‌اندازی کرد که پاسخ JSON بدهد یا یک صفحه‌ی ساده تولید کند. در نهایت، مدیریت خطا و ثبت خطای بخشی از سیستم است، نه یک استثناء؛ بنابراین انتظار می‌رود خطاها ثبت شوند و سیستم تا حد امکان به اجرای خود ادامه دهد.